Internações hospitalares no SUS (SIH/RD), 2022–2024

Projeto Final — Parte 1 · Introdução a Big Data e Data Analytics

Edryck Nascimento
Novembro de 2026

1. Contexto e perguntas

O Sistema de Informações Hospitalares do SUS (SIH/SUS) registra cada internação paga pelo SUS numa Autorização de Internação Hospitalar (AIH). O arquivo reduzido (RD) traz, por AIH, o paciente (idade, sexo, raça/cor, município de residência), o diagnóstico principal (CID-10), o procedimento, as datas, a permanência, o óbito e o valor aprovado. O recorte do projeto cobre as 27 UFs e os 36 meses de 2022 a 2024, num pipeline reprodutível em camadas bronze → silver → gold, com PySpark e PostgreSQL. O trabalho busca um panorama geral e responde a cinco perguntas:

1. **Tendência:** como evoluíram as internações e a taxa bruta por 100 mil habitantes por UF de residência? Há sazonalidade?
2. **Causas:** quais capítulos da CID-10 mais internam?
3. **Valor aprovado:** qual o valor médio aprovado pelo SUS por internação, por UF do hospital?
4. **Permanência e óbito:** como a permanência e a letalidade hospitalar variam por idade, sexo e causa?
5. **Desigualdade regional:** que proporção dos pacientes se interna fora do município onde mora?

2. Fontes e volume

Fonte	Conteúdo	Acesso
DATASUS SIH/RD	972 arquivos `.dbc` (27 UFs × 36 meses)	FTP `ftp.datasus.gov.br`
IBGE/SIDRA	população municipal (Censo 2022, estimativa 2024; 2023 interpolado) e IPCA mensal	API SIDRA
DATASUS TabWin	CID-10 → capítulo, códigos de município (`.cnv`, largura fixa)	FTP
IBGE/geobr	malhas de municípios e UFs	pacote `geobr`

Métrica	Valor
Arquivos / meses / UFs	972 / 36 / 27
Linhas (AIHs)	40.048.092
Colunas no DBF	113, iguais nos três anos (hash do layout idêntico)
Tamanho DBC → Parquet bronze	3,0 GB → 2,1 GB (snappy, todas as colunas como texto)
Silver tipada / gold	1,6 GB (35 colunas) / fato com 12,7 mi linhas

O Parquet compensou: num mês de SP (2,67 mi linhas), o CSV ocupa 1.265 MB e o Parquet 129 MB. Ler 4 colunas levou 9,3 s no CSV e 0,8 s no Parquet, porque o formato colunar só lê as colunas pedidas.

Dificuldades da coleta. O FTP do DATASUS derruba conexões com frequência (erro 425). A solução foi gravar o download num `.part`, conferir o tamanho e só então renomear, com 5 tentativas e espera crescente; arquivos completos são pulados ao rodar de novo. O formato `.dbc` (DBF comprimido) exigiu o `pyreaddbc`. A tabela de CID em CSV citada na documentação não existe no FTP, então os capítulos vieram do `.cnv` do TabWin. A tabela 6579 do SIDRA não tem 2022 e 2023, então 2022 veio do Censo e 2023 foi interpolado linearmente. Os metadados de cada arquivo estão em `reports/metadados_coleta.csv`.

3. Problemas de qualidade e decisões

Nenhuma linha foi apagada. Os problemas foram corrigidos, viraram a categoria `ignorado` ou foram marcados com uma flag. O log completo (16 regras) está em `reports/log_limpeza.csv` e é regravado a cada execução.

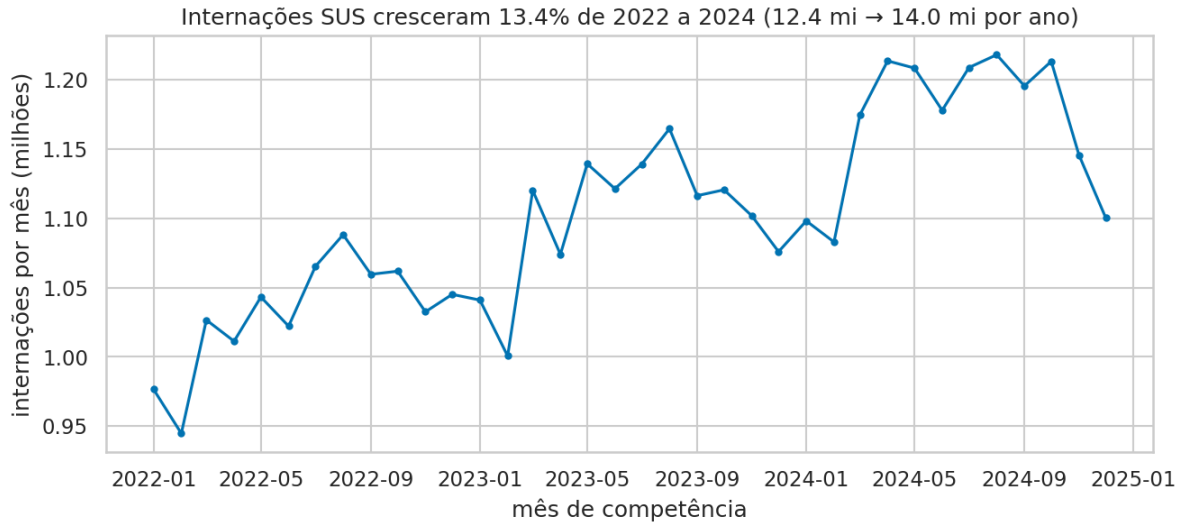
Problema	Linhas afetadas	Decisão
Outlier de `VAL_TOT` (IQR por procedimento)	4.673.037	marcado, não removido: procedimentos caros são reais
Outlier de `DIAS_PERM` (IQR por procedimento)	2.829.313	marcado
`RACA_COR` = 99 (sem informação)	2.778.438	categoria `ignorado`; 19% em 2022 e 0,02% em 2024
AIH de longa permanência (`IDENT=5`)	417.700	fica fora das contagens, porque continua uma internação já contada
`DIAS_PERM` ≠ saída − entrada	413.848	mantido o valor informado (regra de cobrança do SIH)
`VAL_TOT` ≤ 0	124.309	vira nulo nas médias, mas a internação continua nas contagens
Idade inválida (> 120 anos ou código 0)	454	faixa `ignorado`
CID U09/U10 fora da tabela TabWin	184	atribuído ao capítulo XXII

Outras decisões: `UF_ZI` é o município gestor, não a UF; a UF de residência vem de `MUNIC_RES` e a UF do hospital vem do arquivo. Os códigos de município de 7 dígitos foram cortados para 6, e `000000` virou `ignorado`. `VAL_TOT` é o **valor aprovado pelo SUS**, e não o custo real; ele foi deflacionado pelo IPCA para dez/2024. Duplicatas exatas: zero. Todas as repetições de `N_AIH` são AIHs de longa permanência.

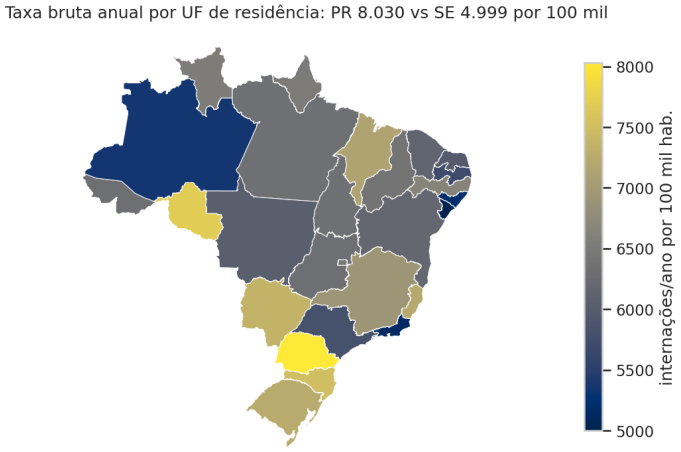
4. Resultados

Q1 — Tendência. As internações passaram de 12,4 milhões em 2022 para 14,0 milhões em 2024 (+13,4%). A série mostra queda em janeiro e fevereiro e alta de março a agosto (Figura 1). A queda em nov–dez de 2024 é, ao menos em parte, atraso de processamento: AIHs podem ser apresentadas até meses depois. A taxa bruta anual

varia de 4.999 internações por 100 mil habitantes em SE a 8.030 no PR (Figura 2). Taxas baixas no Nordeste combinam com a menor cobertura da rede SUS em algumas UFs e com o fato de que parte dos moradores se interna em UFs vizinhas.

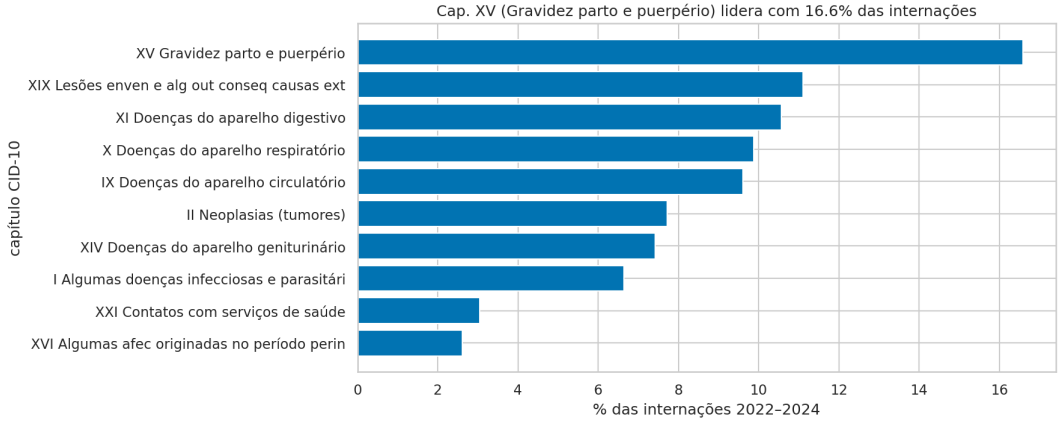


Internações SUS por mês, 2022–2024



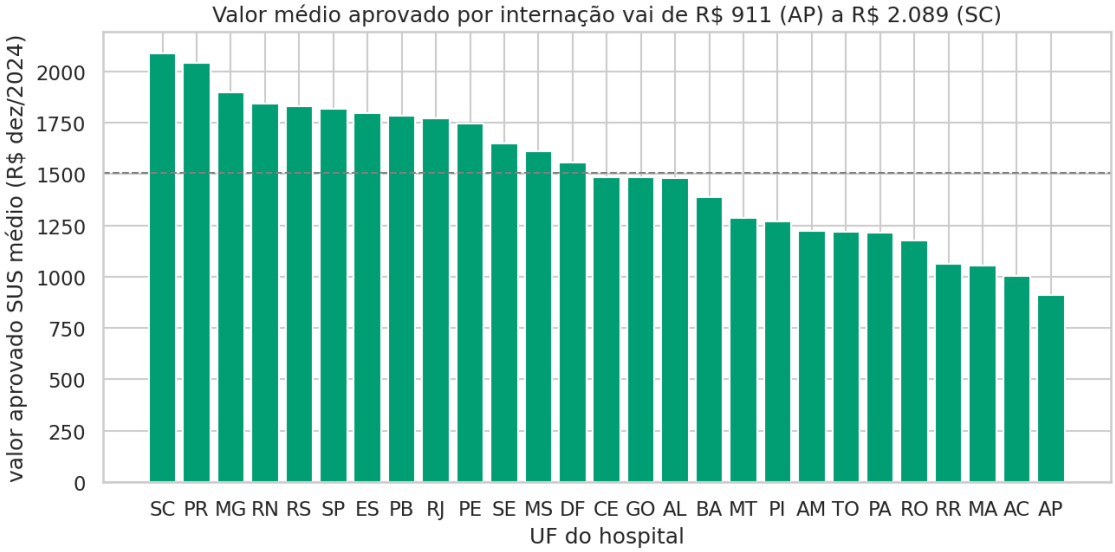
Taxa bruta anual de internações por 100 mil habitantes, por UF de residência

Q2 — Causas. Gravidez, parto e puerpério (cap. XV) lideram com 16,6% das internações. Depois vêm lesões e causas externas (XIX, 11%), aparelho digestivo (XI), respiratório (X) e circulatório (IX) (Figura 3).



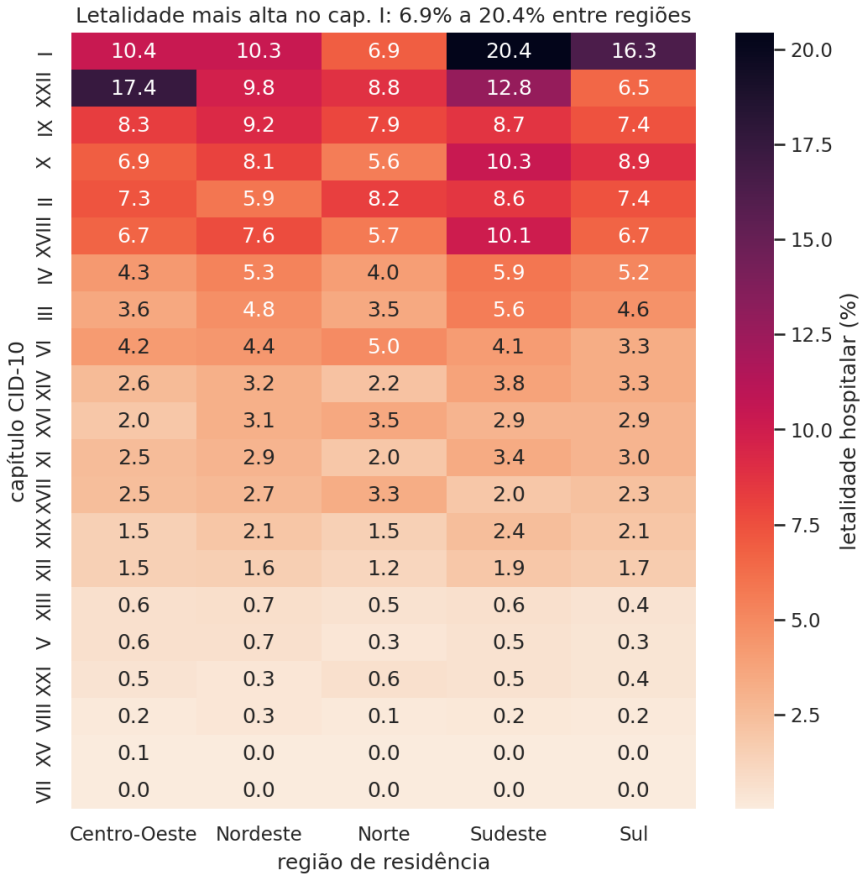
Capítulos da CID-10 com mais internações

Q3 — Valor aprovado. O valor médio aprovado por internação vai de R$ 911 (AP) a R$ 2.089 (SC), a preços de dez/2024 (Figura 4). Sul e Sudeste concentram hospitais de alta complexidade (cardiologia, oncologia, UTI). O valor acompanha os dias de UTI (ρ = 0,46) mais do que a idade (ρ = 0,19), na correlação de Spearman sobre uma amostra de 2% (figura 5 do notebook).



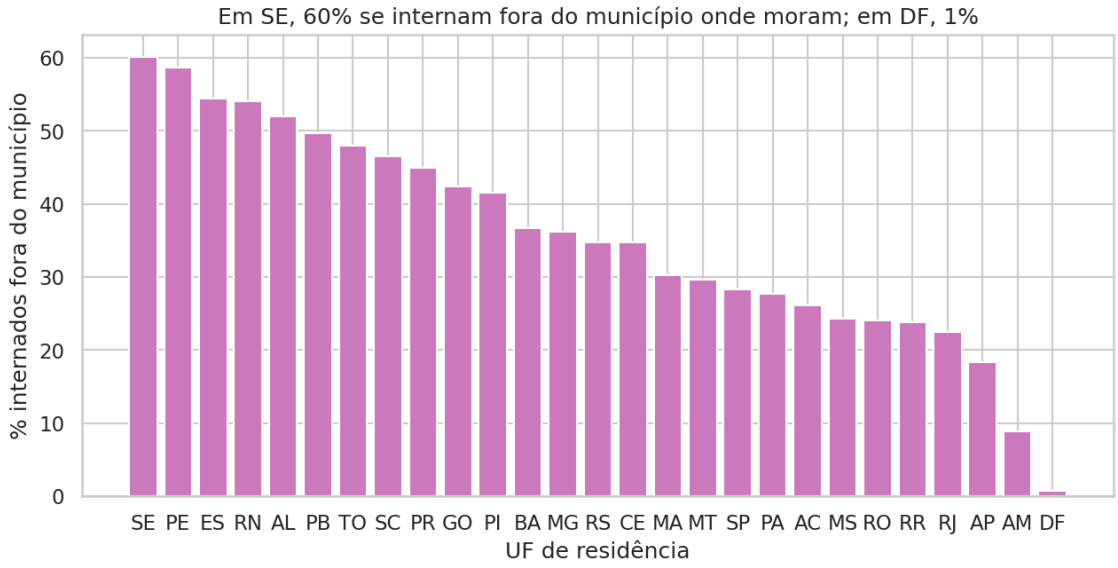
Valor aprovado SUS médio por internação, por UF do hospital

Q4 — Permanência e óbito. A permanência mediana sobe de 2 dias (20–29 anos) para 4 dias (80+). Homens ficam mais tempo entre 15 e 69 anos, e a diferença some acima de 70 anos. A letalidade hospitalar cresce com a idade, de 0,4% (5–9 anos) e 0,6% (20–29) para 7,4% (60–69) e 18,4% (80+); menores de 5 anos ficam em 1,6%, pelo peso dos recém-nascidos. Por causa, as doenças infecciosas (cap. I, que inclui sepse) têm a maior letalidade: 20,4% no Sudeste e 6,9% no Norte. Os códigos especiais (XXII, COVID-19) chegam a 17,4% no Centro-Oeste (Figura 5).



Letalidade hospitalar (%) por capítulo CID-10 e região de residência

Q5 — Internação fora do município. Em SE, 60% dos pacientes se internam fora do município onde moram; em PE, 58%; em ES, RN e AL, mais de 50%. No DF, praticamente 0%, porque o DF é um município só (Figura 6). Esses números mostram quanto a internação se concentra nas capitais e nos polos regionais, e o quanto o paciente precisa se deslocar.



Proporção de internados fora do município de residência, por UF de residência

O notebook (`notebooks/projeto_final.ipynb`, seção 4) traz também a permanência por idade e sexo, a matriz de correlação e o antes/depois da limpeza. O dashboard em

Power BI, montado sobre o schema `dw` do PostgreSQL, segue `reports/tutorial_powerbi.md`.

5. Limitações

- As taxas são **brutas**: o denominador é a população total, sem padronização por idade. UFs mais envelhecidas tendem a ter taxas maiores.
- `VAL_TOT` é o valor de reembolso da tabela SUS, e não o custo real.
- A população de 2023 é interpolada; a de 2024 é estimativa.
- O SIH cobre só internações pagas pelo SUS. A rede privada e os planos de saúde ficam de fora, o que pesa mais nas UFs com mais beneficiários de planos.
- Os últimos meses podem estar incompletos por atraso no envio das AIHs.
- Hadoop (HDFS) e MongoDB não foram usados. Os 40 milhões de linhas cabem em uma máquina com Spark local e Parquet, e o dado é tabular e bem estruturado, o que favorece um banco relacional (PostgreSQL) para o modelo estrela.

6. Próximos passos (Parte 2)

- Taxas padronizadas por idade, usando a população por faixa etária do IBGE.
- Séries temporais com decomposição de sazonalidade e previsão de demanda por UF.
- Modelos de risco de óbito hospitalar (idade, causa, UTI, região).
- Fluxos origem–destino entre municípios (pacientes que se deslocam), com análise de rede.